

Football : Qui va gagner ?

par QRT

Vous devrez rendre un notebook jupyter commenté (c'est-à-dire avec des commentaires et sortie de texte analysant vos résultats).

Vous devez utiliser les fonctions et librairie que nous avons étudiés en TP pour répondre à la problématique (décrite dans **contexte**)

La séance de la semaine du 18 novembre est dédiée à ce projet. Cependant nous vous conseillons de démarrer le projet plus tôt.

Le projet est à déposer sur Moodle pour le

- 24 Novembre à 23h (pour le sillon 2)
- 26 Novembre à 23h (pour le sillon 2)

sur Moodle (pas de retard accepté).

Le rendu attendu est un ou plusieurs notebook.

Le projet peut être fait par binôme ou bien seul(e).

Veillez inscrire votre nom ou binôme dans ce document

https://docs.google.com/spreadsheets/d/1Ta3Cxsx1B2z03Dyd5glsFpqfe3_zeo6xtwWVKx6F74A/edit?usp=sharing

Pensez à préciser votre binôme dans le notebook.

Vous devrez également préparer une présentation (~8 minutes) de votre travail qui sera faite pour la dernière séance de TP (25 et 27 novembre selon votre sillon). Votre chargé(e) de TP vous communiquera votre horaire de passage.

Toutes les données sont accessibles ici

https://drive.google.com/drive/folders/1UJ_Y3ycP_atU-USKrW6spFKk4hRTuYLn?usp=sharing

Contexte

Au cours des vingt dernières années, les professionnels sportifs du monde entier ont adopté une approche fondée sur les données pour adapter leur prise de décision. Les analyses de métriques sportives sont aujourd'hui présentes partout, dans toutes les retransmissions en direct, dans l'eSport et même les discussions quotidiennes. Cette évolution a été notamment alimentée par une croissance exponentielle de la richesse de ces données.

Les équipes et les joueurs, de sport et d'eSport, ainsi que les parieurs professionnels font donc appel à la Data Science et au Machine Learning pour prendre les décisions les plus éclairées. Les sites de paris sportifs sont devenus très sophistiqués dans ce domaine, et certains modèles peuvent également être utilisés par les managers d'équipes ou des recruteurs pour constituer des équipes et déployer stratégiquement des joueurs de manière à maximiser leurs chances de victoire.

Le football a été au cœur de la révolution de l'analyse sportive. Tout type de métriques, à la fois historiques et en temps réel, sont aujourd'hui disponibles. Ce challenge s'appuie sur des données de football obtenues auprès de Sportmonks, un fournisseur majeur de données sportives largement utilisées dans ce domaine. Pour plus de détails, n'hésitez pas à consulter le site sportmonks.com.

Ce projet est une modification de celui proposé par à challengedata.qube-rt.com (vous pouvez le consulter pour plus d'informations sur le challenge, les données et QRT).

But

Dans le cadre du data challenge QRT de cette année, vous devez proposer

- un **modèle de clustering** (vous pouvez choisir ce que vous voulez clusteriser : les joueurs, les matchs, les équipes).
- un **modèle de prédiction de résultat de match**. Vous recevrez des données historiques réelles au niveau des équipes et des joueurs, et **vous devrez prédire quelle équipe gagne ou s'il y a un match nul**.

Les données couvrent de nombreuses ligues dans le monde entier ainsi que différentes divisions.

Description des données

Vous disposerez de données au niveau des équipes et des joueurs pour des dizaines de ligues de football.

Les données sont regroupées dans deux fichiers zip, **X_train.zip** et **X_test.zip**, ainsi que dans deux fichiers csv **Y_train.csv** et **Y_train_supp.csv**.

Les fichiers zip contiennent les données d'input, qui sont divisées en 4 fichiers csv. Les données sont séparées en **HOME** et **AWAY**, au grain des équipes et des joueurs. Toutes les métriques proviennent de matchs historiques réels, agrégés depuis le début de la saison ainsi que sur les 5 derniers matchs précédant le match à prédire.

La colonne **ID** représente un ID de match et relie les 4 tables du **X_train**, avec **Y_train** et **Y_train_supp**. Il en va de même pour les données de test.

Les ensembles de données d'input pour les équipes comprennent les trois colonnes d'identification suivantes : **ID**, **LEAGUE** et **TEAM_NAME** (notez que **LEAGUE** et **TEAM_NAME** ne sont pas inclus dans les données de test).

Vous aurez alors les 25 métriques suivantes, déclinées en somme cumulée, moyenne et écart-type :

- 'TEAM_ATTACKS'
- 'TEAM_BALL_POSSESSION'
- 'TEAM_BALL_SAFE'
- 'TEAM_CORNERS'
- 'TEAM_DANGEROUS_ATTACKS'
- 'TEAM_FOULS'
- 'TEAM_GAME_DRAW'
- 'TEAM_GAME_LOST'
- 'TEAM_GAME_WON'
- 'TEAM_GOALS'
- 'TEAM_INJURIES'
- 'TEAM_OFFSIDES'
- 'TEAM_PASSES'
- 'TEAM_PENALTIES'
- 'TEAM_REDCARDS'
- 'TEAM_SAVES'
- 'TEAM_SHOTS_INSIDEBOX'
- 'TEAM_SHOTS_OFF_TARGET'
- 'TEAM_SHOTS_ON_TARGET'
- 'TEAM_SHOTS_OUTSIDEBOX'
- 'TEAM_SHOTS_TOTAL'
- 'TEAM_SUBSTITUTIONS'
- 'TEAM_SUCCESSFUL_PASSES'
- 'TEAM_SUCCESSFUL_PASSES_PERCENTAGE'
- 'TEAM_YELLOWCARDS'

Les ensembles de données d'input pour les joueurs comprennent les cinq colonnes d'identification suivantes : **ID**, **LEAGUE**, **TEAM_NAME**, **POSITION** et **PLAYER_NAME** (notez que **LEAGUE**, **TEAM_NAME** et **PLAYER_NAME** ne sont pas inclus dans les données de test).

Vous aurez alors les 52 métriques, déclinées en somme cumulée, moyenne et écart-type. Elles sont similaires à celles des équipes bien que plus fines.

Les ensembles de données de sortie sont composés de 4 colonnes :

- ID : identifiant unique de match - correspondant aux ID d'input,
- HOME_WINS,
- DRAW,
- AWAY_WINS,

Le score cible est l'accuracy de la prédiction pour les trois classes [HOME_WINS, DRAW, AWAY_WINS], Il existe donc pour un match trois outputs possibles, [1,0,0], [0,1,0] et [0,0,1].

Nous avons fourni autant de données que possible dans l'ensemble de train, mais toutes les variables ont été normalisées et les noms des équipes, des joueurs et des ligues ont été supprimés de l'ensemble de test.

Un exemple de fichier de soumission contenant des prédictions aléatoires est fourni. Il y a également un notebook benchmark que vous trouverez dans les `supplementary_files`.

Nous avons inclus une autre target d'entraînement **GOAL_DIFF_HOME_AWAY**, qui est la différence de buts entre l'équipe **HOME** et **AWAY**, dans le fichier **Y_train_supp**.

Disclaimer : Les données fournies sont exclusivement destinées à être utilisées dans le cadre de ce challenge, et toute utilisation de cet ensemble de données à d'autres fins est strictement interdite. Les conditions générales d'utilisation sont applicables : [conditions d'utilisation](#).